資料的描述：展現與探索資料

4

學習目標

- 繪製與解釋點圖
- 找出與計算位置量數
- 繪製與分析箱形圖
- 計算與解釋偏態係數
- 繪製與解釋散布圖
- 計算與解釋相關係數
- 建立與解釋列聯表

點圖

點圖在分類資料之後，卻不會喪失原始資料的特性

為製作點圖，沿著水平軸把每個觀測值用點呈現，再用數值標示出來

若有相同的觀測值或是觀察值距離太近以致無法個別展現，就把點「往上疊」

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

點圖

Applewood 汽車集團的四間經銷商中，Tionesta Ford Lincoln 及 Sheffield 兩間汽車經銷商在過去一個月都營業 24 天。下表為上個月兩間經銷商所提供車輛服務的數目。請製作點圖，並摘要報告統計數字，以比較這兩間經銷商

Tionesta Ford Lincoln					
星期一	星期二	星期三	星期四	星期五	星期六
23	33	27	28	39	26
30	32	28	33	35	32
29	25	36	31	32	27
35	32	35	37	36	30

Sheffield Motors Inc.					
星期一	星期二	星期三	星期四	星期五	星期六
31	35	44	36	34	37
30	37	43	31	40	31
32	44	36	34	43	36
26	38	37	30	42	33

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

學習目標1：繪製與解釋點圖。

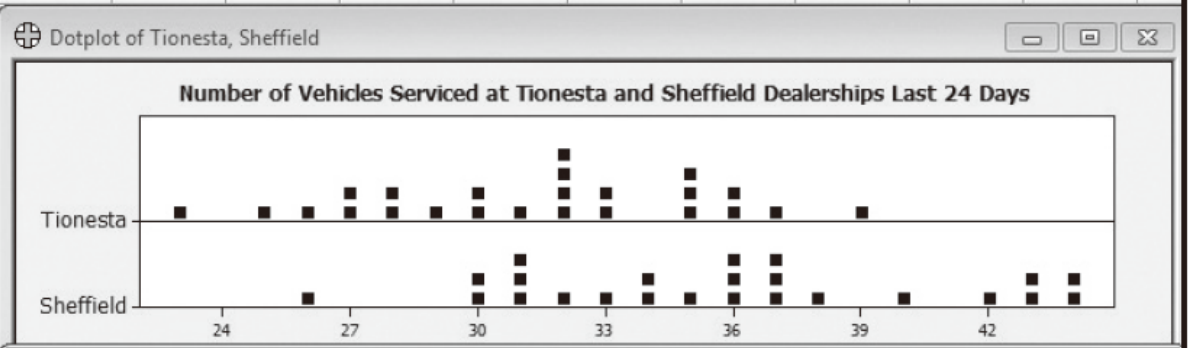
點圖(續)

解答

- Minitab

Worksheet 1 ***

	C1	C2
	Tionesta	Sheffield
1	23	31
2	30	30
3	29	32
4	35	26
5	33	35
6	32	37
7	25	44
8	32	38
9	27	44
10	28	43
11	36	36
12	35	37
13	28	36
14	33	31
15	31	34
16	37	30
17	39	34



Session

Descriptive Statistics: Tionesta, Sheffield

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3	Maximum
Tionesta	24	0	31.292	0.839	4.112	23.000	28.000	32.000	35.000	39.000
Sheffield	24	0	35.83	1.01	4.96	26.00	31.25	36.00	39.50	44.00

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

位置量數

標準差是測量資料離散程度最常用的方法

其他測量資料離散程度的方法之一是: 將一組排序好的觀測值分為相同等分的數值位置

包括四分位數(quartiles)、十分位數(deciles) 及百分位數(percentiles)

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

位置量數

四分位數(quartiles)將資料切成四等分

第一個四分位數為Q1，表示有25%的數據低於此數據

第二個四分位數為Q2(即中位數)，表示有50%的數據低於此數據

第三個四分位數為Q3，表示有75%的數據低於此數據

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

計算百分位數

將計算過程公式化，令L_p代表第p個百分位數的位置。因此，第92個百分位數的位置為L_{92}，而中位數，亦即第50個百分位數，其位置標示為L_{50}

對n個觀測值而言，如果想要找到第p個百分位數，可以使用下面的公式：

第 P 個百分位數的位置 (4-1)

$$L_p = (n+1)\frac{P}{100}$$

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數

Morgan Stanley是一家遍布全美的大型投資公司。下表是該公司在加州奧克蘭分公司15個營業員上個月得到的業績獎金資料

$2,038	$1,758	$1,721	$1,637	$2,097	$2,047	$2,205	$1,787	$2,287
1,940	2,311	2,054	2,406	1,471	1,460			

求出業績獎金的中位數、第一個四分位數及第三個四分位數

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數(續)

解答

- 先將資料由小到大進行排列：

$1,460	$1,471	$1,637	$1,721	$1,758	$1,787	$1,940	$2,038	$2,047
2,054	2,097	2,205	2,287	2,311	2,406			

- 中位數或L_{50}落在$(n+1)$ (50/100) 的位置，其中n是觀測值的個數。在本例中，中位數落在第8個觀測值，由(15+1)(50/100)得出。因此，中位數是$2,038

華泰文化 since 1974 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數(續)

- 求出第一和第三四分位數的位置：

$$L_{25} = (n+1)\frac{P}{100} = (15+1)\frac{25}{100} = 4$$

$$L_{75} = (n+1)\frac{P}{100} = (15+1)\frac{75}{100} = 12$$

- 因此，第一個與第三個四分位數分別在第4與第12個位置，對應的數值是$1,721與$2,205。所以，第一個四分位數是$1,721，第三個四分位數是$2,205

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數(續)

在前面的例子使用公式所計算出來的值剛好是整數。

假如一組資料包含六個數值：91、75、61、101、43與104。在計算第一個四分位數時，必須先將觀測值由小到大排列：43、61、75、91、101 與104，因此，第一個四分位數的位置在：

$$L_{25} = (n+1)\frac{P}{100} = (6+1)\frac{25}{100} = 1.75$$

第一個四分位數位在第一個與第二個資料之間0.75倍的距離上。第一個數值是43，第二個數值是61。因此，第一個四分位數是 43＋0.75×（61－43）= 56.5

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數(Minitab)

下圖是由Minitab輸出Morgan Stanley佣金資料的摘要，包括第一個及第三個四分位數，以及其他統計量。

根據輸出的四分位數，25% 的佣金少於$1,721，75%少於$2,205。這些都跟使用公式 (4-1) 所得到的結果一樣。

Sheet1 ***

↓	C1
	Commissions
1	1460
2	1471
3	1637
4	1721

Session

Descriptive Statistics: Commissions

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3	Maximum
Commissions	15	0	1947.9	77.1	298.8	1460.0	1721.0	2038.0	2205.0	2406.0

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

百分位數(Minitab) (續)

除了前述的方法(排除法)之外，還有其他種求出四分位數的方法。其中一種被稱為包含法(Inclusive Method)，使用$0.25n + 0.75$的公式來找出第一個四分位數的位置，以及用$0.75n + 0.25$來找出第三個四分位數的位置。(參考)

Morgan Stanley Commisisons
$2,038
1,758
1,721
1,637
2,097
2,047
2,205
1,787
2,287
1,940
2,311
2,054
2,406
1,471
1,460

Method	Exclusive	Inclusive
First Quartile	1,721.0	1,739.5
Median	2,038.0	2,038.0
Third Quartile	2,205.0	2,151.0

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

箱形圖

箱形圖（box plot，又稱盒鬚圖）是根據四分位數，協助我們描述一組資料的圖形

製作箱形圖時，只需要五種統計量：最小值、Q_1（第一個四分位數）、中位數、Q_3（第三個四分位數）及最大值

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

箱形圖

Alexander 披薩店免費提供外送披薩的範圍在 15英里內。老闆 Alex 想要一些有關披薩遞送時間的相關資訊：通常要花多少時間遞送？大部分外送在什麼時間範圍內可以完成？根據 20 次外送的樣本資料，他得到下列的資訊：

- 最小值 = 13 分鐘
- Q_1 = 15 分鐘
- 中位數 = 18 分鐘
- Q_3 = 22 分鐘
- 最大值 = 30 分鐘

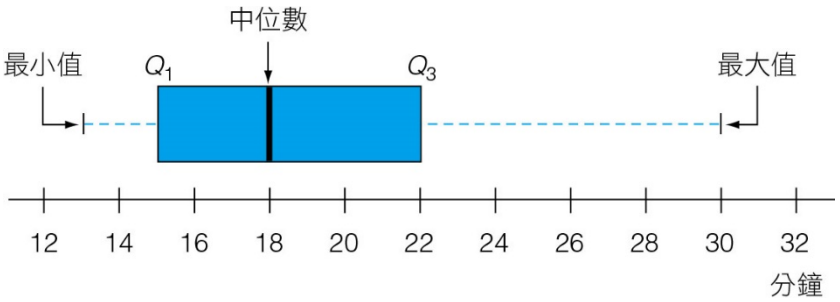


根據上述資訊建構箱形圖。有關外送的時間，你的結論是什麼？

箱形圖(續)

解答

- 步驟1：沿水平軸建立適當刻度
- 步驟2：繪製一個從 Q_1（15 分鐘）開始到 Q_3（22 分鐘）結束的箱子。箱內我們繪製一條垂直線表示中位數（18 分鐘）
- 步驟3：從箱子延伸水平線到最小值（13分鐘）和最大值（30分鐘）

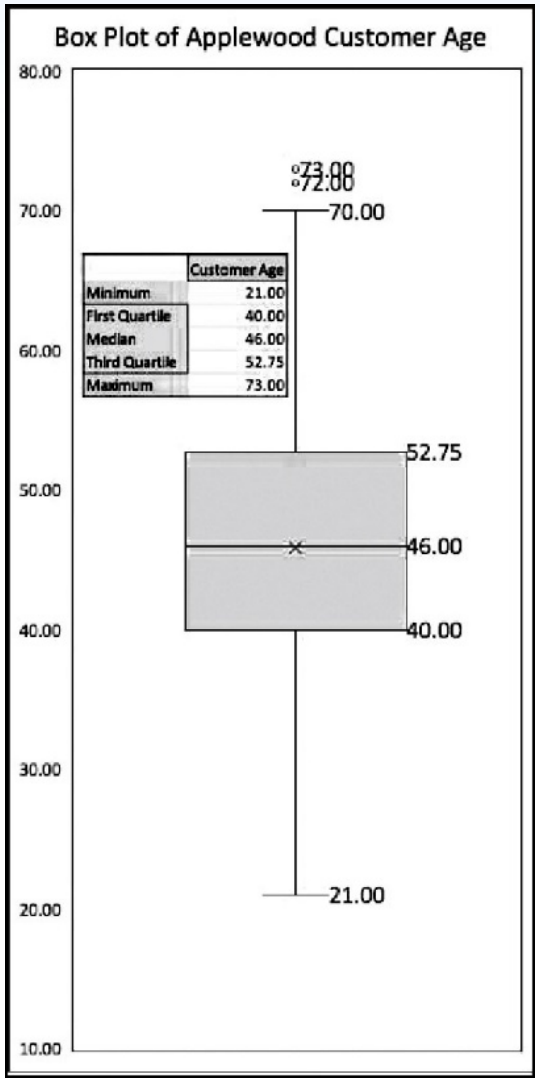


- 第一個與第三個四分位數之間的距離， 稱為四分位數間距(interquartile range)，四分位數間距是7分鐘，表示50%的遞送時間是在15與22分鐘間

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

箱形圖—使用Excel

請參閱 Applewood 汽車集團的資料。以購買者年齡為變數來製作箱形圖。對於汽車購買者年齡分配的結論是什麼？



解答

- 使用Excel 得出右邊的圖形和摘要統計量
- 購買者年齡的中位數是 46 歲，25% 的購買者年齡在 40 歲以下，25% 的購買者年齡超過 52.75 歲。根據摘要資訊以及箱形圖，得出以下結論：

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

箱形圖—使用Excel (續)

- 50% 的汽車購買者年齡介於40 歲和52.75 歲之間。
- 年齡呈現對稱分布，有兩個原因。
  - 52.75 歲(Q3) 以上的鬍鬚長度大約與40 歲(Q1) 以下的鬍鬚長度差不多。
  - 盒子中40 歲到中位數46 歲的面積與中位數到52.75 歲的面積大致相同。
- 在箱形圖中，鬍鬚以上或以下的點代表離群值(outliers)。離群值是與其他資料不一致的數值，它被定義為比Q_3大或是比Q_1 小的幅度超過1.5 倍四分位數間距的數值

偏態

第3章已經說明過使用平均數、中位數及眾數來描述一組觀測值的集中趨勢。同時也說明了測量一組資料離散程度的方法，例如全距與標準差

資料的另一個特徵是分配的形狀。通常分配的形狀可以分為四種：

1. 對稱
2. 正偏
3. 負偏
4. 雙峰

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

分配的形狀

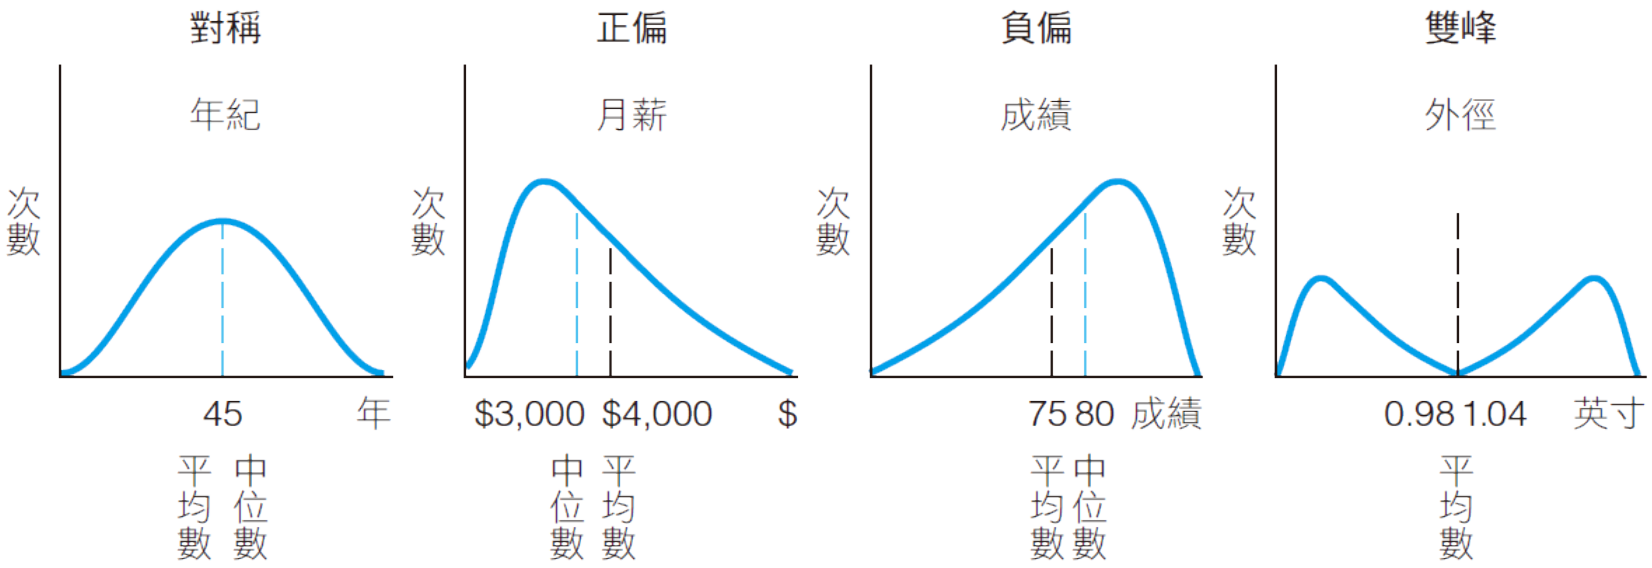


圖4-1　次數多邊形圖的形狀

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

偏態—計算公式

皮爾森偏度係數的範圍是在−3 至3之間。

例如，−2.57表示為強負偏分配；1.63 表示為中度正偏分配；0表示平均數與中位數相等，為對稱分配，即無偏態

皮爾森偏態係數 (4-2)

$$sk = \frac{3(\bar{x} - \text{中位數})}{s}$$

統計軟體的偏態係數 (4-3)

$$sk = \frac{n}{(n-1)(n-2)}\left[\sum\left(\frac{x-\bar{x}}{s}\right)^3\right]$$

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

偏態

以下是 15 家軟體公司在2022 年每股盈餘的樣本資料，每股盈餘由小到大排列

$0.09	$0.13	$0.41	$0.51	$ 1.12	$ 1.20	$ 1.49	$3.18
3.50	6.36	7.83	8.92	10.13	12.99	16.40	

計算平均數、中位數與標準差，並使用皮爾森公式與軟體方法計算偏態係數。關於分配的形狀，你的結論是什麼？

偏態(續)

解答

使用皮爾森係數

- 因為這是樣本資料，所以使用公式 (3-2) 來計算平均數：

$$\bar{x} = \frac{\Sigma x}{n} = \frac{\$74.26}{15} = \$4.95$$

- 中位數是一組資料經過排序之後位於中間的數值。在本例中，中間值為$3.18，因此每股盈餘的中位數為$3.18
- 使用公式 (3-10) 來計算樣本標準差

$$s = \sqrt{\frac{\Sigma(x - \bar{x})^2}{n-1}} = \sqrt{\frac{(\$0.09 - \$4.95)^2 + \cdots + (\$16.40 - \$4.95)^2}{15-1}} = \$5.22$$

- 皮爾森偏態係數是1.017，計算過程如下：

$$sk = \frac{3(\bar{x} - \text{中位數})}{s} = \frac{3(\$4.95 - \$3.18)}{\$5.22} = 1.017$$

偏態(續)

- 使用軟體方法

步驟1：計算平均數

$$\bar{x} = \frac{\Sigma x}{n} = \frac{\$74.26}{15} = \$4.95$$

步驟2：計算標準差

$$s = \sqrt{\frac{\Sigma(x - \bar{x})^2}{n-1}} = \sqrt{\frac{(\$0.09 - \$4.95)^2 + \cdots + (\$16.40 - \$4.95)^2}{15-1}} = \$5.22$$

步驟3：計算 $\Sigma\left(\frac{x-\bar{x}}{s}\right)^3$

步驟4：計算

$$sk = \frac{n}{(n-1)(n-2)} \sum\left(\frac{x-\bar{x}}{s}\right)^3 = \frac{15}{(15-1)(15-2)}(11.8274) = 0.975$$

學習目標4：計算與解釋偏態係數。

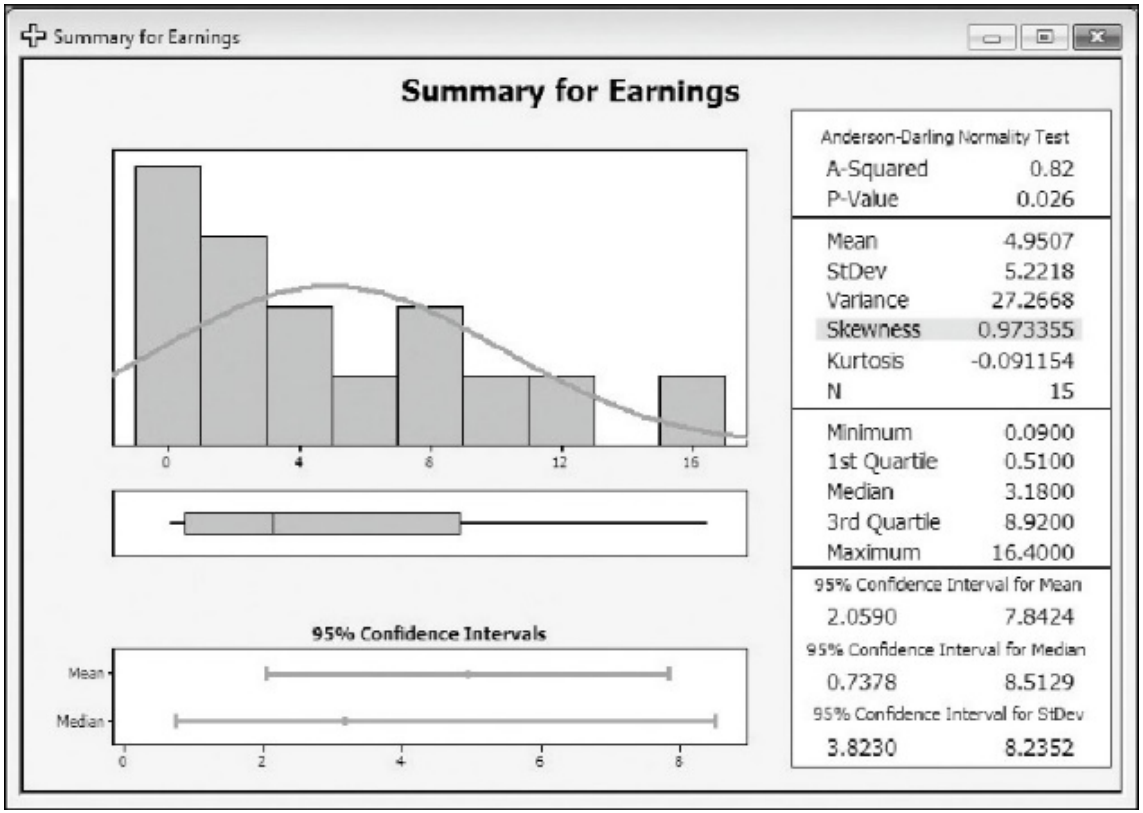
表4-1　偏態係數的計算

每股盈餘	$\frac{(x-\bar{x})}{s}$	$\left(\frac{(x-\bar{x})}{s}\right)^3$
0.09	−0.9310	−0.8070
0.13	−0.9234	−0.7873
0.41	−0.8697	−0.6579
0.51	−0.8506	−0.6154
1.12	−0.7337	−0.3950
1.20	−0.7184	−0.3708
1.49	−0.6628	−0.2912
3.18	−0.3391	−0.0390
3.50	−0.2778	−0.0214
6.36	0.2701	0.0197
7.83	0.5517	0.1679
8.92	0.7605	0.4399
10.13	0.9923	0.9772
12.99	1.5402	3.6539
16.40	2.1935	10.5537
		11.8274

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

偏態(續)

Minitab



since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

描述兩變數間的關係

在本章剛開始用點圖為一組資料做視覺化的呈現。因為在探討單一變數，所以將此資料稱為單變數(univariate)資料

在某些情形下，需要探討並視覺化兩個變數之間的關係。此種資料稱為雙變數(bivariate)資料

通常用散布圖(scatter diagram)來呈現變數之間的關係

為了繪製散布圖，需要兩個變數。沿著水平軸（X軸）標示一個變數，並沿著垂直軸（Y軸）標示另一個變數

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

散布圖　用來顯示兩個以區間或比例尺度衡量的變數之間關係的圖形技術

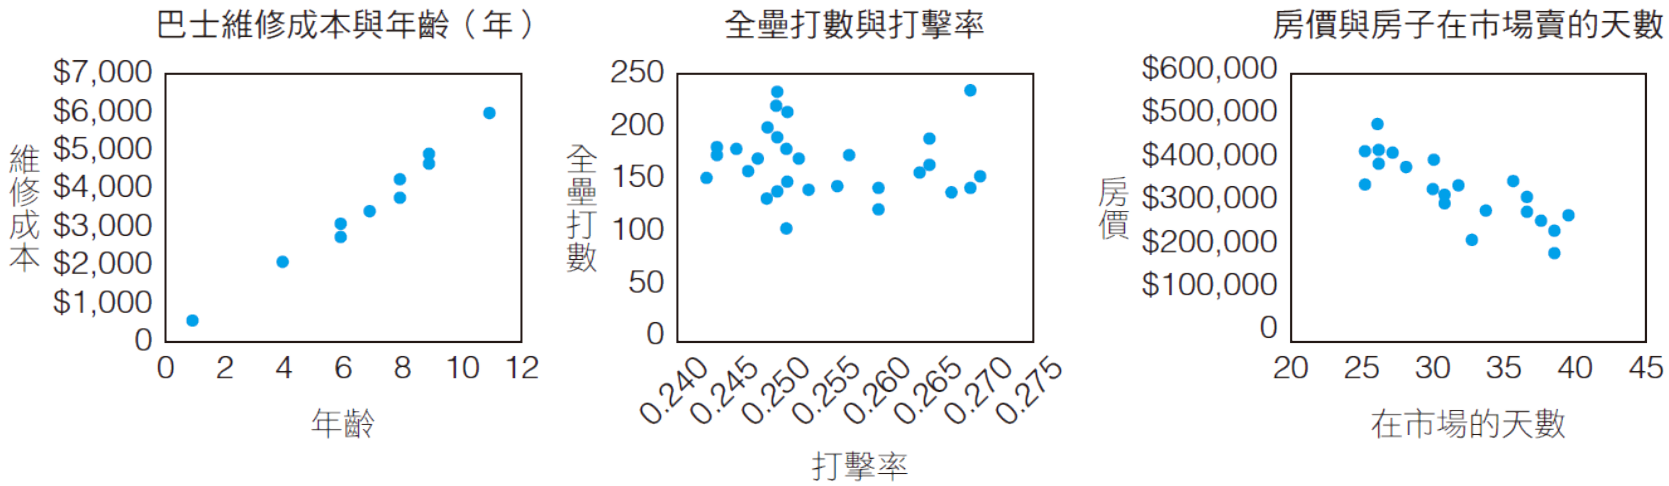


圖4-2　散布圖的三個例子

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

描述兩變數間的關係—散布圖Excel

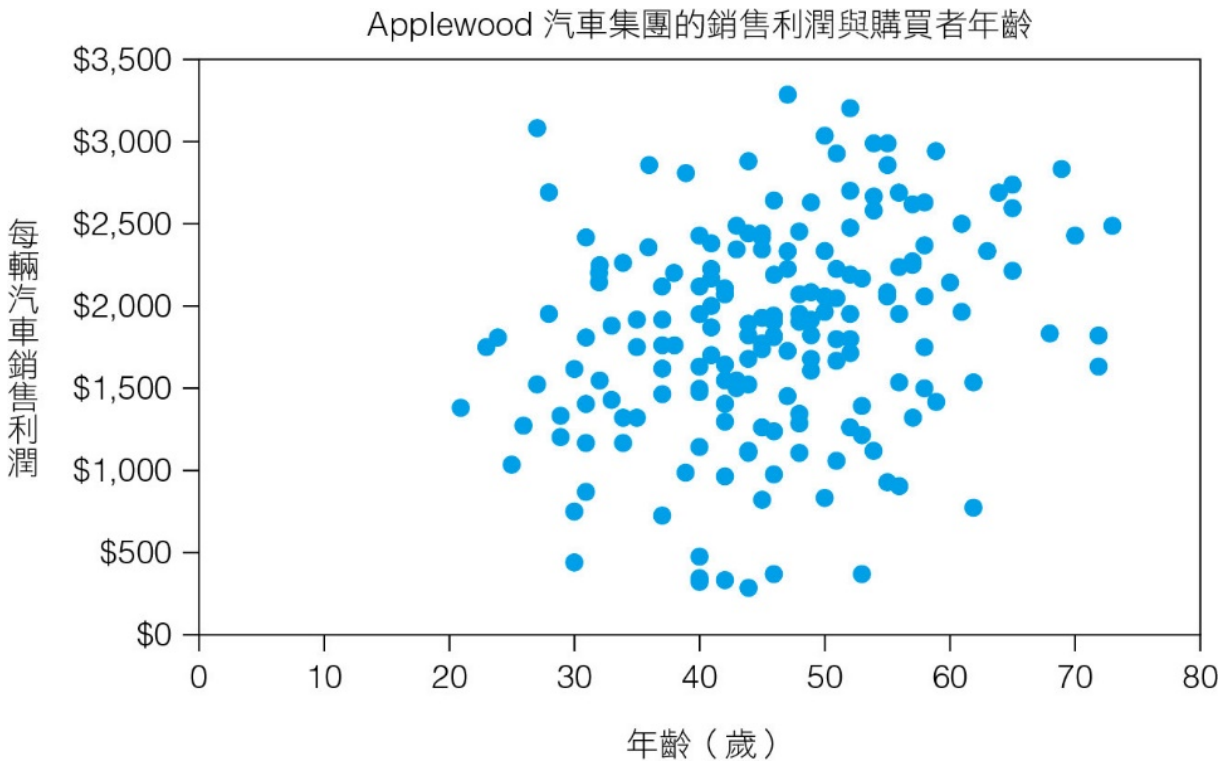
在第2.1 節的簡介中，展示Applewood 汽車集團的資料。變數是上個月180 輛汽車的銷售利潤。

除了每輛車的銷售利潤外，另一個變數為購買者年齡。這兩個變數間是否有關？賣汽車給年紀較大的購買者，是否能賺取較多的利潤？

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

描述兩變數間的關係—散布圖Excel (續)

$$r = \frac{\Sigma(x - \bar{x})(y - \bar{y})}{(n-1)s_x s_y} = 0.26$$



華泰文化 since 1974 HWA TAI PUBLISHING
華泰網路書店eShop

列聯表

散布圖要求兩變數至少必須是區間尺度

如果有一個或兩個變數是名目或順序尺度時，要如何研究變數之間的關係？在此種情形下，把變數的資料彙整於列聯表(contingency table)中

列聯表　根據兩個可識別特徵，將樣本觀測值分類的表格

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

列聯表(續)

列聯表是同時摘要兩個所關注變數的交叉表格。例如：

- 大學生按照居住地（州內或州外）與年級來分類（大一、大二、大三、大四）
- 公司的產品根據可接受與否來分類，以及根據製造的時間（早上、下午或晚上）來分類
- 學校債券公投的選民以他們參與的政黨（民主黨、共和黨、其他）和他們在該學區就讀的子女數（無、1位、2位等）來分類

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

列聯表

Applewood汽車集團有四間經銷商，假設想要比較每間經銷商的銷售利潤。換句話說，經銷商與銷售利潤是否有關係？

解答

- 把資訊整理成列聯表，便可以比較四間經銷商的銷售利潤。觀察到以下情形：

展示銷售利潤與經銷商關係的列聯表

大於／小於中位數利潤	Kane	Olean	Sheffield	Tionesta	總計
大於	25	20	19	26	90
小於	27	20	26	17	90
總計	52	40	45	43	180

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

列聯表(續)

- 從右邊總計那欄來看，180 輛中的 90 輛之銷售利潤超過中位數，而另一半少於中位數。從中位數的定義來看，這是符合預期的
- 至於 Kane 經銷商，52 輛中的 25 輛（或者說是 48%）之銷售利潤超過中位數
- 其他經銷商的銷售利潤超過中位數的有：Olean 占 50%，Sheffield 占 42%，Tionesta 占 60%

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop

Excel應用

中位數	=MEDIAN(範圍)
第一四分位數 Q1	=QUARTILE.INC(範圍,1)
第三四分位數 Q3	=QUARTILE.INC(範圍,3)
任意第p個百分位數	=PERCENTILE.INC(範圍, p/100)
最小值	=MIN(範圍)
最大值	=MAX(範圍)
四分位數間距 IQR	=QUARTILE.INC(範圍,3)-QUARTILE.INC(範圍,1)
平均數	=AVERAGE(範圍)
標準差	=STDEV.S(範圍)
軟體法偏態係數	=SKEW(範圍)
皮爾森偏態係數	=3*(AVERAGE(範圍)-MEDIAN(範圍))/STDEV.S(範圍)
相關係數	=CORREL(範圍1,範圍2)

since 1974 華泰文化 HWA TAI PUBLISHING
華泰網路書店eShop